

Теория автоматов и формальных языков

Магазинные автоматы

Автор: Екатерина Вербицкая


НИУ-ВШЭ

10 октября 2022

- Регулярные языки распознаются с помощью конечных автоматов
- Разные алгоритмы синтаксического анализа для контекстно-свободных языков
 - ▶ CYK
 - ▶ Рекурсивный спуск
 - ▶ LL(1)
- Есть ли универсальный распознаватель для КС-языков?

- Произвольный КС язык можно распознать при помощи магазинного автомата (он же автомат с магазинной памятью, он же pushdown automata, он же pda)
- Магазинный автомат по сути — автомат со стеком
- Детерминированные магазинные автоматы могут распознавать только детерминированные КС языки
- Недетерминированные магазинные автоматы могут распознавать произвольные КС языки

Что такое магазинный автомат



Что такое магазинный автомат: неформально

- Автомат, переходы которого осуществляются по входному символу, текущему состоянию и символу на вершине стека
 - ▶ У конечного автомата не было стека
- Никакие состояния стека, кроме вершины, не доступны
- Во время перехода может изменяться стек
 - ▶ Положить что-то на стек (push)
 - ▶ Снять верхушку со стека (pop)
- A может и не изменяться
 - ▶ Магазинный автомат может вообще игнорировать стек
 - ▶ Или стек может не изменяться, хоть значение оттуда и читается
- Итого: по тройке (входной символ, состояние, символ на вершине стека) получается новое состояние, и модифицируется (или нет) стек

Формальное определение


Недетерминированный магазинный автомат это $(Q, \Sigma, \Gamma, \delta, q_0, \perp, F)$

- Q — конечное множество состояний
- Σ — конечное множество символов, входной алфавит
- Γ — конечное множество символов, стековый алфавит
- $\delta : Q \times (\Sigma \cup \varepsilon) \times \Gamma \rightarrow 2^{Q \times \Gamma^*}$ — функция переходов
- $q_0 \in Q$ — стартовое состояние
- $\perp \in \Gamma$ — начальный элемент стека
- $F \subseteq Q$ — множество принимающих (конечных) состояний

Отношение переходов


$(q, \alpha) \in \delta(p, a, A)$ означает

- Если магазинный автомат находится в состоянии $p \in Q$,
- на вершине стека находится $A \in \Gamma$,
- а со входа читается символ $a \in \Sigma \cup \varepsilon$,
- то изменяем состояние на $q \in Q$,
- снимаем со стека символ A , записываем на стек строку $\alpha \in \Gamma^*$
- $\Sigma \cup \varepsilon$ сигнализирует о том, что вход можно и не читать



Семантика магазинного автомата


- Мгновенное описание МА: $(p, \omega, \beta) \in Q \times \Sigma^* \times \Gamma^*$
 - ▶ p — текущее состояние автомата
 - ▶ ω — непрочитанный фрагмент входного потока
 - ▶ β — содержимое стека (верхушка записана первой)
- Отношение \vdash на мгновенных описаниях (шаг)
 - ▶ Для каждого $(q, \alpha) \in \delta(p, a, A)$, верно $(p, a\omega, A\alpha) \vdash (q, \omega, \alpha)$ для произвольных $\omega \in \Sigma^*, \alpha \in \Gamma^*$
- Шаг не определен, если стек пуст



Семантика магазинного автомата: вычисление

- Вычисление — последовательность шагов
- Начальное мгновенное описание (q_0, ω, \perp)
- Выбирается любой из подходящих шагов
- Если какой-нибудь выбор приведет к успеху, значит, строка распознается
- Два варианта окончания работы
 - ▶ По достижении конечного состояния
 - ★ $L(M) = \{\omega \in \Sigma^* \mid (q_0, \omega, \perp) \vdash^* (f, \varepsilon, \gamma), f \in F, \gamma \in \Gamma^*\}$
 - ▶ По опустошении стека
 - ★ $N(M) = \{\omega \in \Sigma^* \mid (q_0, \omega, \perp) \vdash^* (q, \varepsilon, \varepsilon), q \in Q\}$
 - ▶ Эти варианты эквивалентны: по автомату, завершающемуся по первой схеме, можно посмотреть автомат, завершающийся по второй схеме, и наоборот
- \vdash^* — транзитивно рефлексивное замыкание отношения \vdash


Пример: язык $\{0^n 1^n \mid n \geq 0\}$ (конечное состояние)



Вычисление на строке 0011:

- $(p, 0011, \perp) \vdash (q, 0011, \perp) \vdash (r, 0011, \perp)$ — провал
- $(p, 0011, \perp) \vdash (p, 011, A\perp) \vdash (q, 011, A\perp)$ — провал
- $(p, 0011, \perp) \vdash (p, 011, A\perp) \vdash (p, 11, AA\perp) \vdash (q, 11, AA\perp) \vdash (q, 1, A\perp) \vdash (q, \epsilon, \perp) \vdash (r, \epsilon, \perp)$ — успех (по принимающему состоянию)


Пример: язык $\{0^n 1^n \mid n \geq 0\}$ (конечное состояние)



Вычисление на строке 00111:

- $(p, 00111, \perp) \vdash (q, 00111, \perp) \vdash (r, 00111, \perp)$ — провал
- $(p, 00111, \perp) \vdash (p, 0111, A\perp) \vdash (q, 0111, A\perp)$ — провал
- $(p, 00111, \perp) \vdash (p, 0111, A\perp) \vdash (p, 111, AA\perp) \vdash (q, 111, AA\perp) \vdash (q, 11, A\perp) \vdash (q, 1, \perp) \vdash (r, 1, \perp)$ — провал

Пример: язык $\{0^n 1^m \mid 1 \leq m \leq n\}$ (опустошение стека)



Вычисление на строке 00111:


- $(p, 00111, \perp) \vdash (q, 00111, \perp)$ — провал
- $(p, 00111, \perp) \vdash (p, 0111, A\perp) \vdash (p, 111, AA\perp) \vdash (q, 11, A\perp) \vdash (q, 1, \perp)$ — провал

Вычисление на строке 001:

- $(p, 001, \perp) \vdash (p, 01, A\perp) \vdash (p, 1, AA\perp) \vdash (q, \varepsilon, A\perp) \vdash (q, \varepsilon, \perp) \vdash (q, \varepsilon, \varepsilon)$ — успех

Пример: язык $\{\omega c \omega^R \mid \omega \in \{0, 1\}^*\}$ (опустошение стека)

$$X \in \{G, B, \perp\}$$



Вычисление на строке 110c011:

- $(p, 110c011, \perp) \vdash (p, 10c011, G\perp) \vdash (p, 0c011, GG\perp) \vdash$
 $(p, c011, BGG\perp) \vdash (q, 011, BGG\perp) \vdash (q, 11, GG\perp) \vdash (q, 1, G\perp) \vdash$
 $(q, \varepsilon, \perp) \vdash (q, \varepsilon, \varepsilon) \text{ — успех}$

Формальное определение ДМА

Детерминированный магазинный автомат это $(Q, \Sigma, \Gamma, \delta, q_0, \perp, F)$

- Q — конечное множество состояний
- Σ — конечное множество символов, входной алфавит
- Γ — конечное множество символов, стековый алфавит
- $\delta : Q \times (\Sigma \cup \varepsilon) \times \Gamma \rightarrow Q \times \Gamma^*$ — функция переходов
 - ▶ $\forall q \in Q, Z \in \Gamma$: если есть эpsilon-переход $\delta(q, \varepsilon, Z)$ то нет переходов по терминалам $\delta(q, a, Z)$
- $q_0 \in Q$ — стартовое состояние
- $\perp \in \Gamma$ — начальный элемент стека
- $F \subseteq Q$ — множество принимающих (конечных) состояний

Детерминированные магазинные автоматы vs недетерминированные

- В общем случае одной входной строке может соответствовать несколько вычислений
 - ▶ Некоторые из них могут завершаться в принимающих состояниях
- Если существует хотя бы одно вычисление, завершающееся в принимающем состоянии, строка принадлежит языку
- Если для каждой строки существует ровно одно вычисление в магазинном автомате, то он является *детерминированным*
 - ▶ Соответствующий язык является *детерминированным КС языком*
- Детерминированный магазинный автомат является частным случаем недетерминированного, поэтому детерминированные КС языки — строгое подмножество контекстно-свободных


Неэквивалентность двух видов приема для детерминированных магазинных автоматов

Беспрефиксный язык — язык, в котором никакое слово не является префиксом другого


- Прием языка детерминированным магазинным автоматом по пустому стеку и по допускающему состоянию эквивалентно только для беспрефиксных языков
- Рассмотрим слово $\omega = \alpha\beta : \alpha, \beta \in \Sigma^*, \omega, \alpha \in L$, где $L \subseteq \Sigma^*$
- При попытке распознать слово ω ДМП завершит свою работу, как только прочитает α
- ω никогда не будет принята
- Можно построить ДМП, принимающий по допускающему состоянию, который допускает префиксный язык

Построение магазинного автомата по КС-грамматике

- Интуиция:
 - ▶ Для каждого нетерминала: заменяем его на стеке на правую часть правила
 - ▶ Для каждого терминала: считываем со входа этот терминал и снимаем со стека
- Построение:
 - ▶ Для каждого правила $A \rightarrow \alpha$ добавляем (q, α) в $\delta(q, \varepsilon, A)$
 - ▶ Для каждого терминала a добавляем (q, ε) в $\delta(q, a, a)$
- Относительно бесполезный автомат: как найти правильное вычисление?



Магазинный автомат по грамматике $S \rightarrow (S)S \mid \varepsilon$




Вычисление на строке $(())()$:

- [illegible]

Построение магазинного автомата по КС-грамматике в нормальной форме Грейбах


- Нормальная форма Грейбах: все правила имеют вид $A \rightarrow x\alpha$
 - ▶ $A \in V_N$
 - ▶ $x \in V_T$
 - ▶ $\alpha \in V_N^*$
- Построение магазинного автомата:
 - ▶ Для каждого правила $A \rightarrow x\alpha$ добавляем (q, α) в $\delta(q, x, A)$
- Автоматы получаются проще: без ε -переходов
- Не сильно более полезный автомат
- НФ Грейбах позволяет реализовывать эффективный парсер рекурсивным спуском



Магазинный автомат по грамматике в НФГ

$S \rightarrow (SRS \mid (R$

$R \rightarrow)$




Вычисление на строке $((()))()$:

- $(q, ((()))(), S) \vdash (q, (())(), SRS) \vdash (q,))(), RRS) \vdash (q,)(), RS) \vdash (q, (), S) \vdash (q,), R) \vdash (q, \epsilon, \epsilon) \text{ — успех}$

Построение КС грамматики по магазинному автомату

- По магазинному автомату $(Q, \Sigma, \Gamma, \delta, q_0, \perp, F)$ строим грамматику (V_N, V_T, P, S)
- $V_N = \{S\} \cup \{[qAp] \mid p, q \in Q, A \in \Gamma\}$
- $V_T = \Sigma$
- $P = \{S \rightarrow [q_0 \perp q] \mid q \in Q\} \cup$
 $\{[qAq_{m+1}] \rightarrow a[q_1B_1q_2][q_2B_2q_3] \dots [q_mB_mq_{m+1}] \mid$
 $q_i \in Q; a \in \Sigma \cup \{\varepsilon\}; A, B_j \in \Gamma; (q_1, B_1B_2 \dots B_m) \in \delta(q, a, A)\} \cup$
 $\{[qAp] \rightarrow a \mid (p, \varepsilon) \in \delta(q, a, A)\}$

Пример построения КС грамматики по магазинному автомату



$$\begin{array}{lcl} [qSq] & \rightarrow & ([qRq] \\ & | & ([qSq] [qRq] [qSq] \\ [qRq] & \rightarrow &) \end{array}$$

Лемма о накачке для КС языков




Лемма

Если язык L является контекстно-свободным, то

$\exists p \geq 1 : \forall \omega \in L : |\omega| \geq p$ можно разбить на подстроки

$\omega = uvwxu : |vwx| \leq p, |vx| \geq 1$ и

$\forall n \geq 0 : uv^nwx^n y \in L$



Лемма о накачке для КС языков: пример

Язык $L = \{a^n b^n c^n\}$

Предполагаем, что он КС, тогда по Лемме существует $p \dots$

Рассмотрим слово $a^p b^p c^p = uvwxu$, $|vwx| \leq p$, $|vx| \geq 1$

- $vwx = a^j, j \leq p$
- $vwx = a^j b^k, j + k \leq p$
- $vwx = b^j, j \leq p$
- $vwx = b^j c^k, j + k \leq p$
- $vwx = c^j, j \leq p$

Строка $uv^i wx^i u$ не содержит одинаковое количество букв для всех i .

Например, рассмотреть $i = 2$. Получили противоречие — успех